In [1]:
```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
import plotly.express as px
sns.set(font='Microsoft YaHei',palette='RdPu',font_scale = 1.1)
from warnings import filterwarnings
filterwarnings("ignore")
```

In [2]:
```
# 导入数据(原始数据是所有华南的都在这了)
data = pd.read_excel(r"D:\钱大妈\对话记录.xlsx")
```

In [3]:
```
pd.set_option('display.max_columns',50)
```

In [4]:
```
data['是否工作日'] = data['week'].apply(lambda x:'workday' if x in(['Monday','Tuesd
```

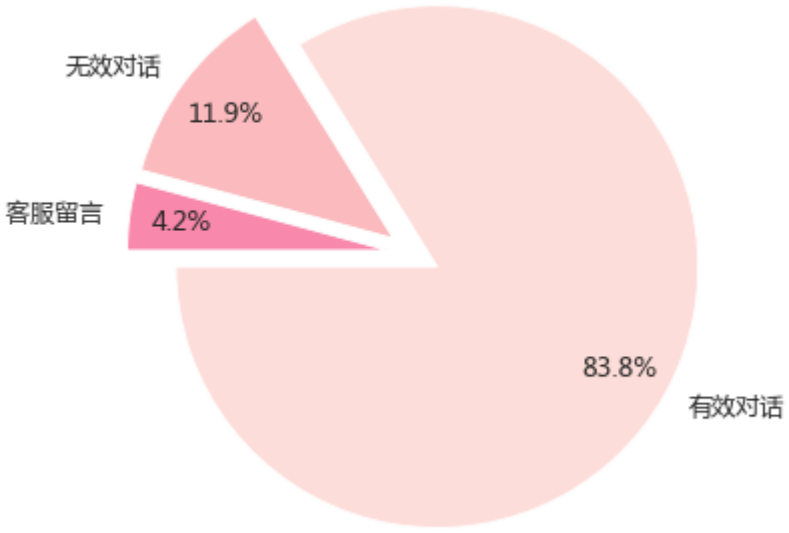
In [5]:
```
data.shape
```

Out[5]:
```
(121729, 38)
```

数据为华南客服部4-5月数据

华南4-5两月的有效对话百分比

In [6]:
```
plt.figure(figsize=(8,6))
sizes = data['是否有效对话'].value_counts().values
labels = data['是否有效对话'].value_counts().index
plt.pie(sizes,labels = labels,autopct='%1.1f%%',startangle=180,explode = [0.1,0.1,00
plt.show()
```

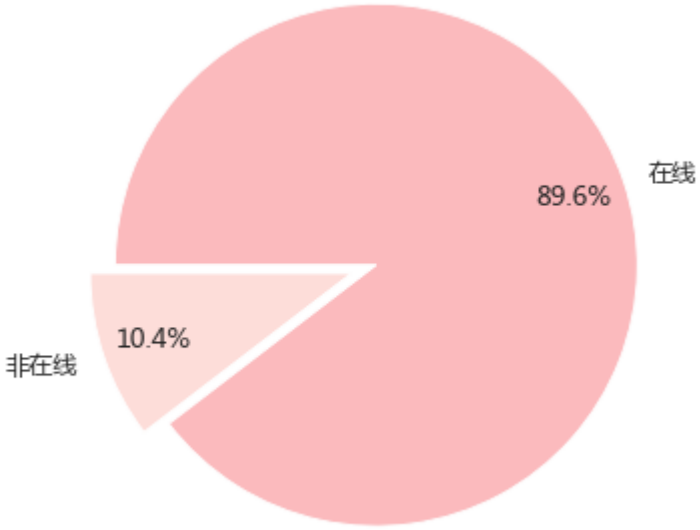


各小组有效对话的占比

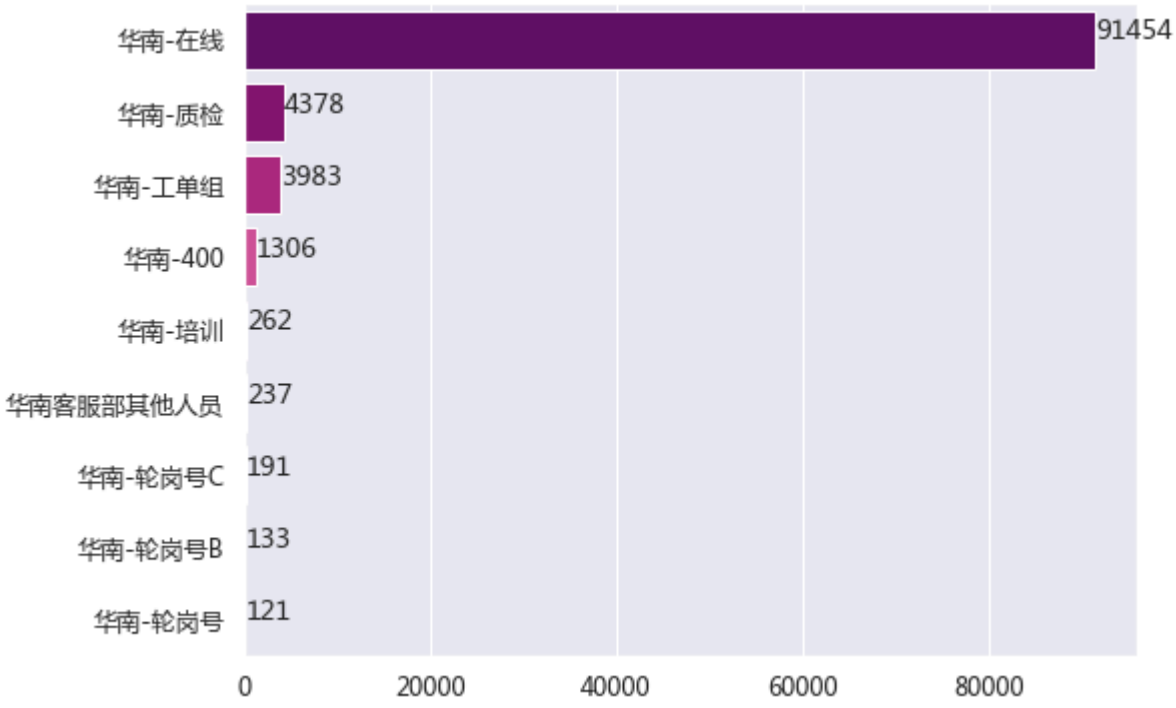
In [7]:
```
ydf = data[data['是否有效对话']=='有效对话']
```

In [8]:
```
ydf['对话时长分组'] = pd.cut(ydf['对话时长-分'],bins = [0,1,2,3,4,5,6,7,8,9,10,11,12
                      labels = ['1m','2m','3m','4m','5m','6m','7m','8m','9m','10m','
```

In [9]:
```
plt.figure(figsize=(8,6))
sizes = [10611,91454]
labels = ['非在线','在线']
plt.pie(sizes,labels = labels,autopct='%1.1f%%',startangle=180,explode = [0.1,0],pct
plt.show()
```



In [10]:
```
plt.figure(figsize=(8,6))
sns.countplot(y = '小类',data = ydf,order = ydf['小类'].value_counts().index,palette
# plt.xticks(rotation = 90)
plt.xlabel('')
plt.ylabel('')
con = list(ydf['小类'].value_counts().values)
for x,y in enumerate(con):
    plt.text(y+0.1,x,'%s' %y)
plt.show()
```



选取华南-在线小组的数据分析对话时长问题

In [11]:
```
zxdf = ydf[ydf['小类']=='华南-在线']
```

工作日与周末的对话量对比

In [12]:
```
workdf = zxdf[zxdf['是否工作日']=='workday']
weekendf = zxdf[zxdf['是否工作日'].isin(['Sunday','Saturday'])]
```

工作日 VS 周末 各时段对话量——日均

In [13]:
```
wm = workdf.groupby(['date','hour']).客服.count().reset_index(name='total')
wm = wm.groupby('hour').total.mean().round(1).reset_index(name = 'mean')

em = weekendf.groupby(['date','hour']).客服.count().reset_index(name='total')
em = em.groupby('hour').total.mean().round(1).reset_index(name = 'mean')

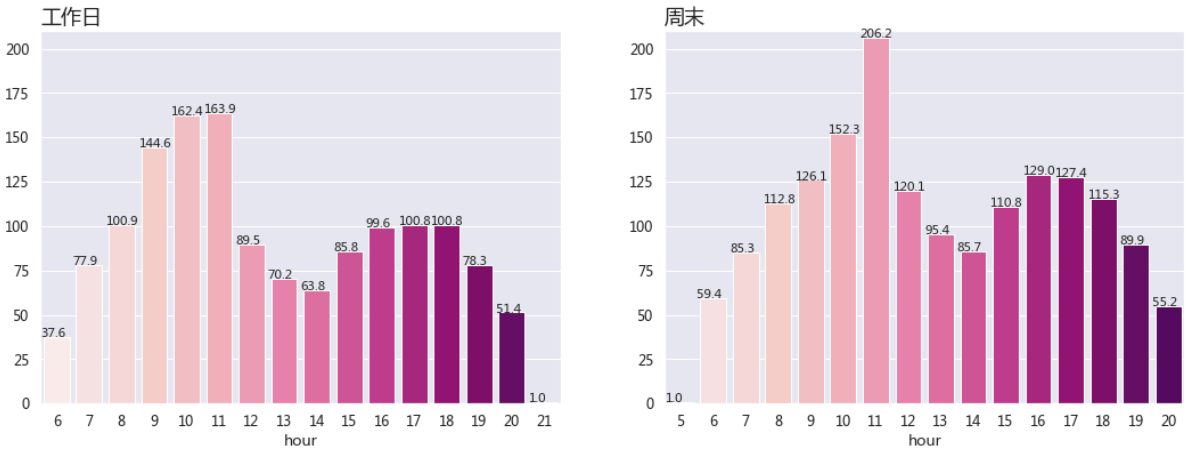
plt.figure(figsize = (18,6))
plt.subplot(1,2,1)
sns.barplot(x = 'hour',y = 'mean',palette = 'RdPu',data = wm)
plt.ylabel('')
plt.ylim(0,210)
con = list(wm['mean'])
for y,x in enumerate(con):
    plt.text(y-0.5,x,'%s' %x,size = 11)

plt.title('工作日',loc = 'left',fontsize = 18)


plt.subplot(1,2,2)
sns.barplot(x = 'hour',y = 'mean',palette = 'RdPu',data = em)
plt.ylabel('')
plt.ylim(0,210)
con = list(em['mean'])
for y,x in enumerate(con):
    plt.text(y-0.5,x,'%s' %x,size = 11)

plt.title('周末',loc = 'left',fontsize = 18)

plt.show()
```



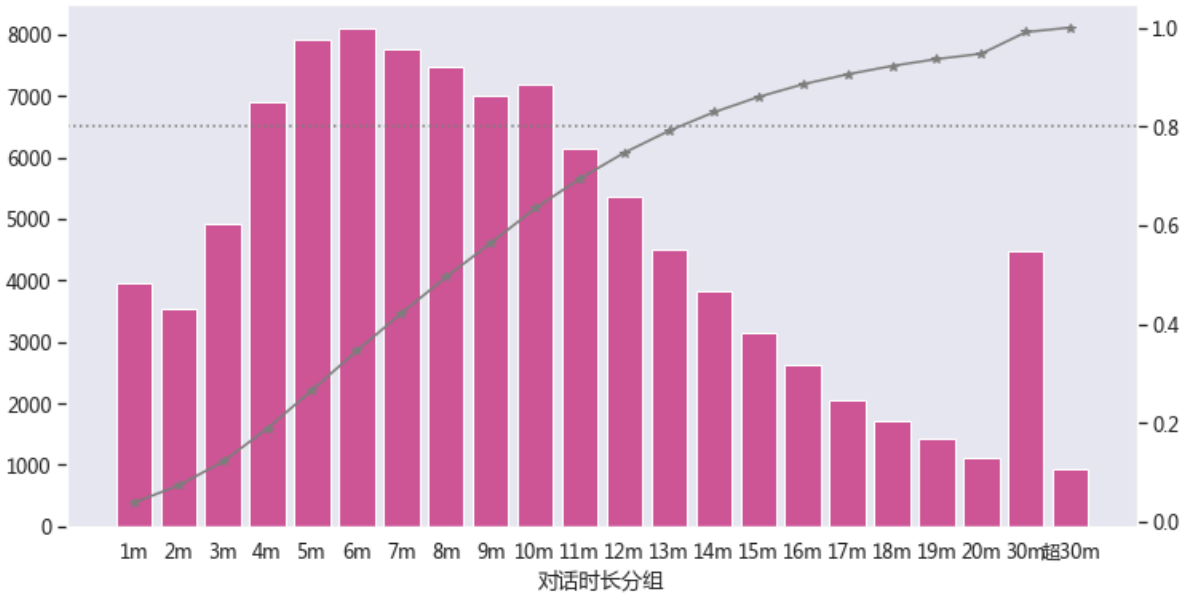
- 可以很明显的发现4-5月的业务量各时段不平稳的情况在周末尤为明显，且周末下午时段高于工作日下午时段的日均量
- 另外11点时段仍处理高峰时段，但该时段恰好是早班午休，晚班未上班的时段，延申分析排队与掉线（排队时间过长放弃排队）、忙线是否也集中在该时段，若是，需重新规划班次时间

帕累托图——各对话时长累计占比

In [23]:
```
rlt = ydf.groupby('对话时长分组').对话时长分组.count().cumsum()/ydf.shape[0]
plt.figure(figsize = (12,6))
# sns.countplot(x = '对话时长分组',data = ydf,palette = 'RdPu_r')

plt.bar(ydf.groupby('对话时长分组').对话时长分组.count().index,ydf.groupby('对话时长

rlt.plot(color = 'gray',secondary_y = True,style = '-*')
plt.axhline(y = 0.8,ls=':',color = 'gray')
plt.grid(False)
plt.ylabel('')
plt.show()
```



63.4%的对话不超过10分钟，79.1%的对话时长不超过13分钟，超过20分钟的对话量占总对话量的 5.3% ， 只有 0.09% 的对话量超 30 分钟

In [15]:
```
rlt.reset_index(name = '累计百分比')
```

Out[15]:

	对话时长分组	累计百分比
0	1m	0.038642
1	2m	0.073198
2	3m	0.121501
3	4m	0.188997
4	5m	0.266477
5	6m	0.345760
6	7m	0.421770
7	8m	0.494939
8	9m	0.563562
9	10m	0.634027
10	11m	0.694136
11	12m	0.746759
12	13m	0.790976
13	14m	0.828384
14	15m	0.859345
15	16m	0.885122
16	17m	0.905296
17	18m	0.922206
18	19m	0.936149
19	20m	0.946965
20	30m	0.990761
21	超30m	1.000000

In [16]:
```
result = zxdf[zxdf['对话时长-分']<30]
# print('对话时长分布')
# sns.jointplot(
#     data=result,
#     x="对话时长-分", y="hour",kind="kde"
# )
# plt.show()
```

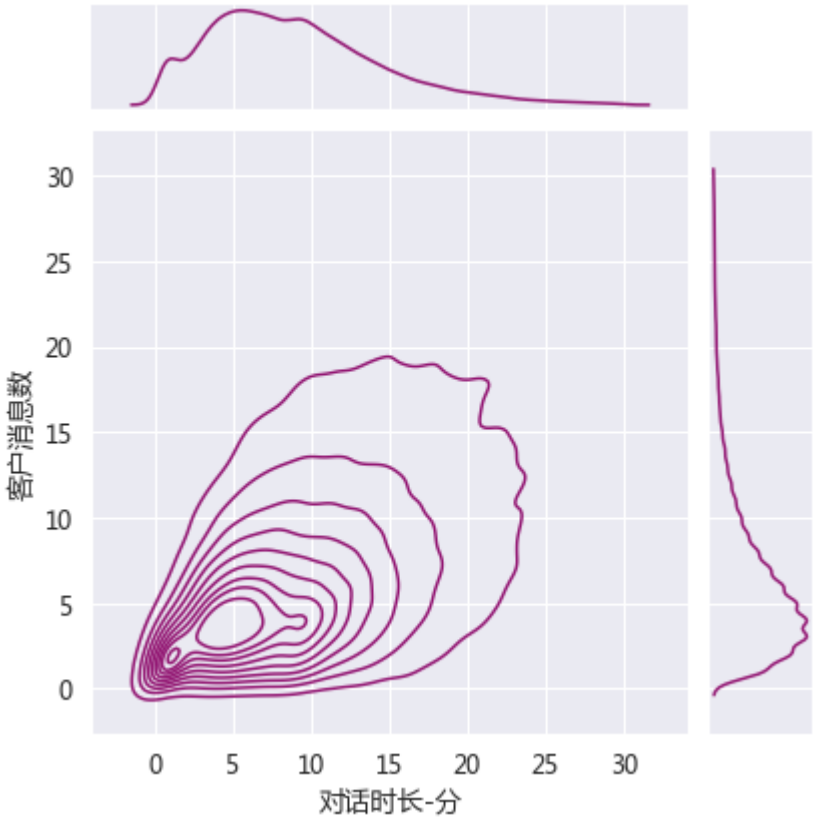
客户消息数与对话时长

In [17]:
```
# sns.scatterplot(x='对话时长-分',y = '客户消息数',data = result)
result1 = result[result['客户消息数']<30]

print('对话时长&客户消息数')
sns.jointplot(
    data=result1,
    x="对话时长-分", y="客户消息数",kind="kde",color = '#931673',

)
plt.show()
```

对话时长&客户消息数



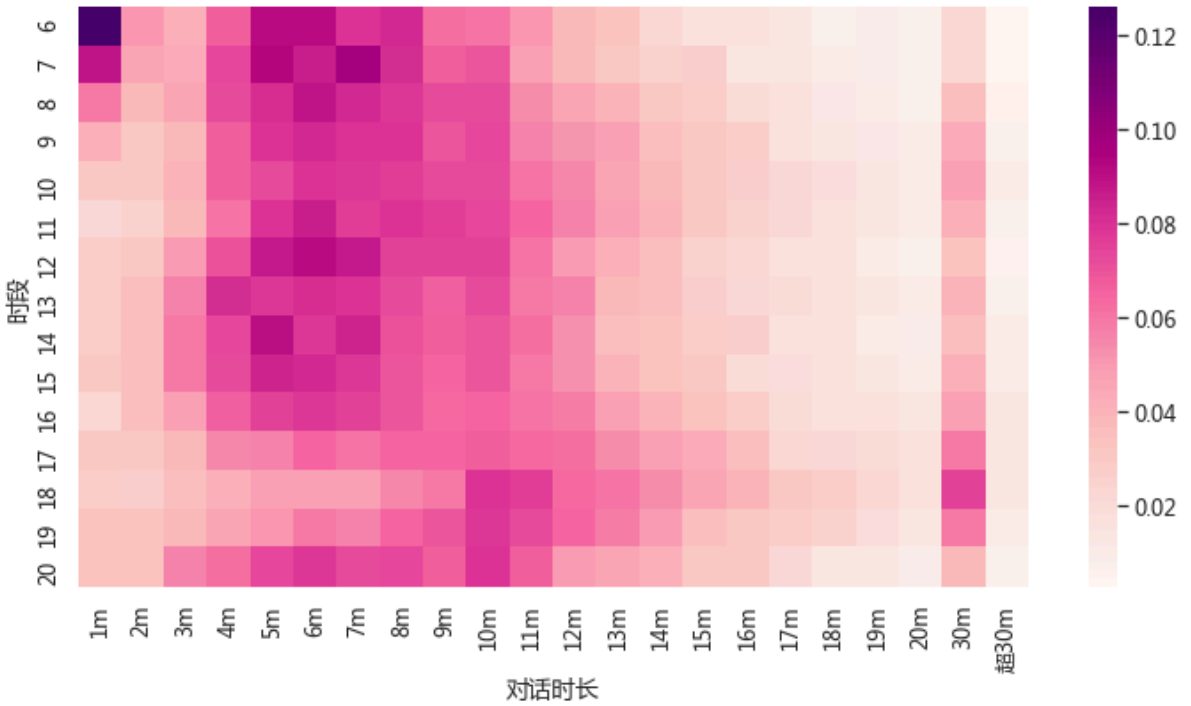
4-5月 整体对话时长分布

In [18]:
```
d1 = zxdf
# d1['hour']=d1['hour'].astype('str')
d1 = d1[(d1['hour']!=21)&(d1['hour']!=5)]

rd1 = d1.groupby(['对话时长分组','hour']).对话时长分组.count().reset_index(name = 't
rd1 = pd.pivot_table(rd1,index = 'hour',values = 'total',columns = '对话时长分组')

pd1 = rd1.div(rd1.sum(axis=1), axis=0).round(3)

plt.figure(figsize = (12,6))
sns.heatmap(pd1,cmap = 'RdPu')
plt.xlabel('对话时长')
plt.ylabel('时段')
plt.show()
```



剔除异常数据（时长>30 m，和客户消息数>30）

对话时长主要集中在5-10分钟内，客户消息数主要集中在 1-7 之间

在线组每人的对话时长

工作日 VS 周末 各时段对话时长分布情况

In [19]:

```
# 工作日
wk = workdf.groupby(['对话时长分组','hour']).对话时长分组.count().reset_index(name =
wk = pd.pivot_table(wk,index = 'hour',values = 'total',columns = '对话时长分组')
ctw = wk.div(wk.sum(axis=1), axis=0).round(3)

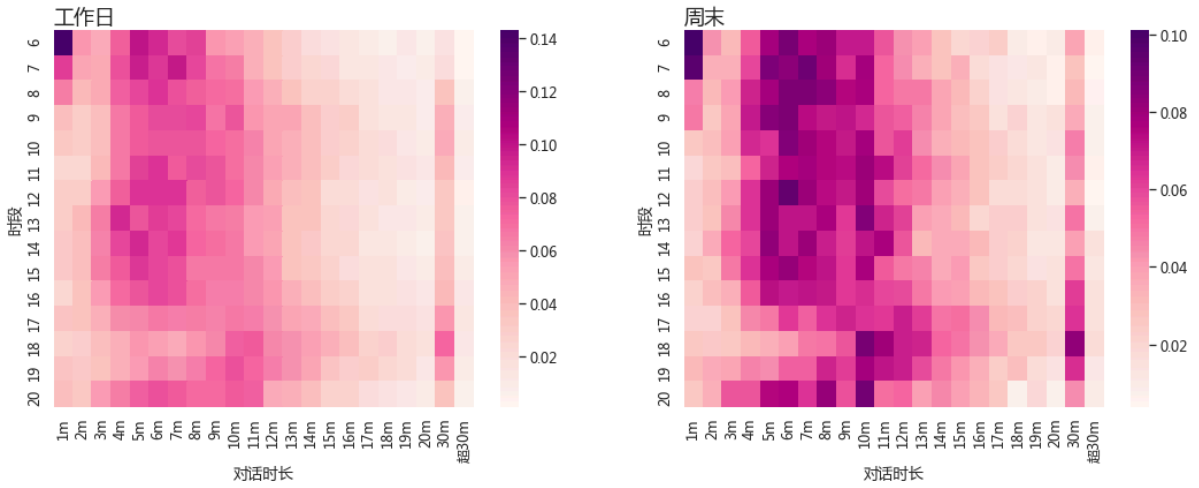
# 周末
we = weekendf.groupby(['对话时长分组','hour']).对话时长分组.count().reset_index(name
we = pd.pivot_table(we,index = 'hour',values = 'total',columns = '对话时长分组')
cte = we.div(we.sum(axis= 1), axis=0).round(3)

# 可视化
plt.figure(figsize = (18,6))
# 工作日
ctw = ctw[ctw.index!=21]
plt.subplot(1,2,1)
sns.heatmap(ctw,cmap='RdPu')
plt.xlabel('对话时长')
plt.ylabel('时段')
plt.title('工作日',loc = 'left',fontsize = 18)

# 周末

cte = cte[(cte.index!=21)&(cte.index!=5)]
plt.subplot(1,2,2)
sns.heatmap(cte,cmap='RdPu')
plt.xlabel('对话时长')
plt.ylabel('时段')
plt.title('周末',loc = 'left',fontsize = 18)

plt.show()
```



- 1.不管是工作日还是周末，对话时长均集中在4-11或4-12分钟之间
- 2.对话时长超过30m的数据中，工作日集中16-20 点 这个时间段，周末集中在16-20 点 这个时间段 ，通常这个时间段会涉及到电商的问题，初步推测这些超长时间的对话大部分来自C端，由于该类超长时间对话不仅影响整体服务数据质量，且占线过长导致排队，响应不及时等等，进而做延申分析查找原因

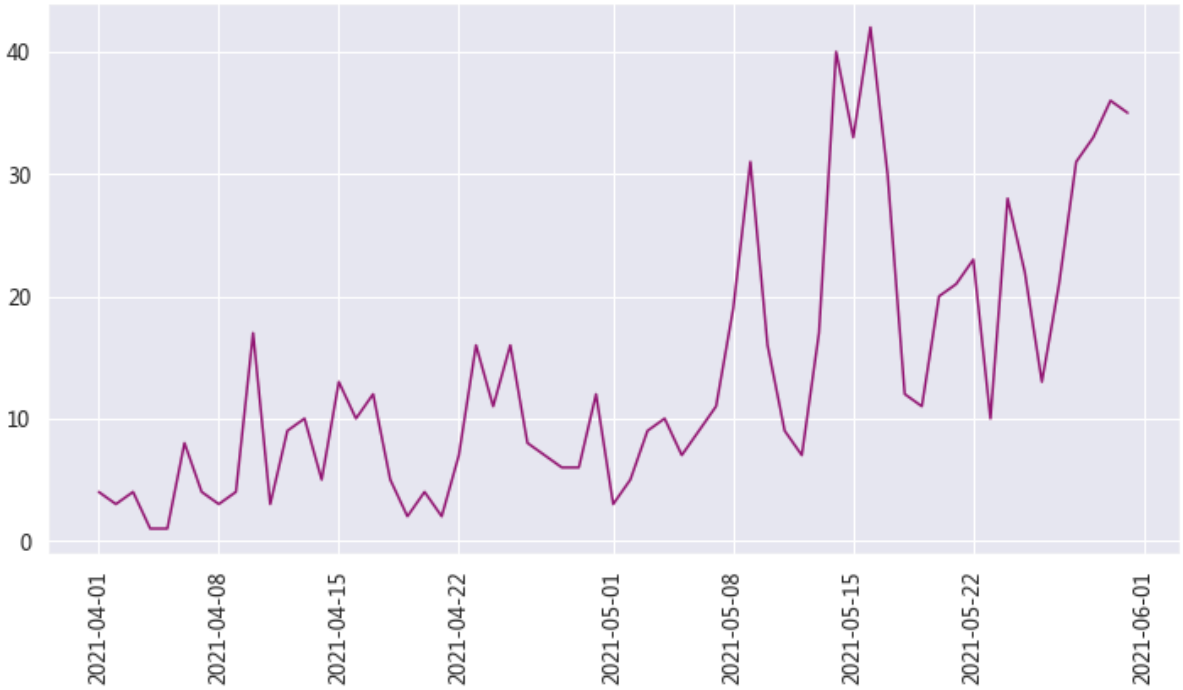
延申专题分析：

- 验证超长时间的对话来自C端/B端的比例
- 集中在哪些问题上-升级客诉建工单的比例（对比历史与现分析阶段）
- 主要来自哪些省市

对话时长超过30分钟的数据中哪些日期最多

In [20]:
```
df_m30 = zxdf[zxdf['对话时长分组']=='超30m']
```

In [21]:
```
result_m30 = df_m30.groupby(['month','date']).客服.count().reset_index(name = 'total
plt.figure(figsize = (12,6))
plt.plot('date','total',data = result_m30,color = '#931673')
# sns.lineplot(x = 'date',y='total',data = result_m30,color = '#931673')
plt.xticks(rotation = 90)
plt.show()
```



- 从上图可以看到4月份对话时长超30分钟对话量普遍在20条以下，但到5月份总体看对话时长超30分钟的对话量突然增加，结合小结工单验证以下问题：
- 1.疫情（不可抗力因素）的影响造成迟到的问题；
- 2.切仓出现的问题；
- 3.活动（5月促销活动的客诉问题-需结小结工单、运营优惠券派发核销、客诉量、客服补偿券进行验证分析）；
- 哪些问题客服没有办法解决，客户得不到满意的答复只能在线发泄情绪导致对话时间过长；

上图对应的超30m的总数如下：

In [22]:
```
result_m30
```

Out[22]:

	month	date	total
0	4	2021-04-01	4
1	4	2021-04-02	3
2	4	2021-04-03	4
3	4	2021-04-04	1
4	4	2021-04-05	1
5	4	2021-04-06	8
6	4	2021-04-07	4
7	4	2021-04-08	3
8	4	2021-04-09	4
9	4	2021-04-10	17
10	4	2021-04-11	3
11	4	2021-04-12	9
12	4	2021-04-13	10
13	4	2021-04-14	5
14	4	2021-04-15	13
15	4	2021-04-16	10
16	4	2021-04-17	12
17	4	2021-04-18	5
18	4	2021-04-19	2
19	4	2021-04-20	4
20	4	2021-04-21	2
21	4	2021-04-22	7
22	4	2021-04-23	16
23	4	2021-04-24	11
24	4	2021-04-25	16
25	4	2021-04-26	8
26	4	2021-04-28	6
27	4	2021-04-29	6
28	4	2021-04-30	12
29	5	2021-05-01	3
30	5	2021-05-02	5
31	5	2021-05-03	9
32	5	2021-05-04	10
33	5	2021-05-05	7
34	5	2021-05-06	9
35	5	2021-05-07	11

	month	date	total
36	5	2021-05-08	19
37	5	2021-05-09	31
38	5	2021-05-10	16
39	5	2021-05-11	9
40	5	2021-05-12	7
41	5	2021-05-13	17
42	5	2021-05-14	40
43	5	2021-05-15	33
44	5	2021-05-16	42
45	5	2021-05-17	30
46	5	2021-05-18	12
47	5	2021-05-19	11
48	5	2021-05-20	20
49	5	2021-05-21	21
50	5	2021-05-22	23
51	5	2021-05-23	10
52	5	2021-05-24	28
53	5	2021-05-25	22
54	5	2021-05-26	13
55	5	2021-05-27	21
56	5	2021-05-28	31
57	5	2021-05-29	33
58	5	2021-05-30	36
59	5	2021-05-31	35

在线组每人的对话时长

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]:

In [ ]: